

Tugas 3 - Outliers Detection

Penambangan Data – Semester Genap 2024/2025

Latar Belakang

Ingat dengan Pak Mindat? Benar sekali, seorang kepala bagian di Dinas Pendidikan DKJ (Disdik DKJ). Beliau menerapkan kebijakan kerja *remote* untuk karyawannya. Untuk memastikan karyawan benar-benar bekerja sesuai jam yang dilaporkan, setiap karyawan diminta mengisi log harian yang kemudian direkapitulasi secara mingguan.

Mekanisme yang diberlakukan oleh Pak Mindat memiliki masalah. Beliau mulai mencurigai bahwa beberapa laporan jam kerja tampak ‘aneh’ (terlalu tinggi atau terlalu rendah dibandingkan karyawan lainnya). Beliau meminta Anda, selaku orang yang paling beliau percaya, untuk mendeteksi siapa saja karyawan yang mungkin membuat laporan jam kerja yang tidak wajar.

Anda diminta untuk menggunakan dua metode:

1. Tukey’s Fence.
2. DBSCAN (Density-Based Spatial Clustering of Applications with Noise).

Tugas Anda adalah membuat analisis **manual** (step-by-step) untuk menentukan karyawan mana saja yang tergolong **outlier** menurut kedua metode tersebut.

Outlier Detection dengan Tukey’s Fence [30 poin]

Pak Mindat memberikan Anda rekap minggu pertama di bulan Februari. Rekap tersebut berisi 12 data karyawan di Disdik DKJ dan **total jam kerja** di minggu tersebut. Data tersebut dapat Anda lihat di bawah.

Nama Karyawan	Total Jam Kerja
Anita	35
Bagas	26
Cinta	32
Dadang	40

Eko	42
Farhan	75
Ginanjjar	28
Hasyim	46
Indira	30
Joko	50
Kinara	65
Lina	38

Bantulah Pak Mindat untuk menjawab pertanyaan-pertanyaan di bawah untuk mencari data yang tidak wajar menggunakan metode **Tukey's Fence**. Ingat, Pak Mindat ingin Anda melakukan **analisis manual** disertai **step-by-step** cara Anda mendapatkan jawabannya.

1. [5 poin] Hitung nilai kuartil (Q1, Q2, Q3)!
2. [5 poin] Hitung nilai IQR (Interquartile Range)!
3. [10 poin] Tentukan nilai **upper fence** dan **lower fence** berdasarkan perhitungan IQR! (gunakan 1.5 sebagai konstanta pengali IQR)
4. [10 poin] Berdasarkan batas tersebut, siapa yang memiliki data total jam kerja yang tidak wajar? Jelaskan alasan dan hasil perhitungan Anda!

Outlier Detection dengan DBSCAN [50 Poin]

Singkat cerita, asisten pribadi Pak Mindat memberikan **rekap kehadiran rapat** pada minggu pertama bulan Februari. Rekap tersebut berisi total berapa jam karyawan Pak Mindat menghadiri rapat. Data tersebut menambahkan informasi baru bagi Anda untuk mencari data yang tidak wajar.

Nama Karyawan	Total Jam Kerja	Total Jam Rapat
Anita	35	5
Bagas	26	2
Cinta	32	3

5. [20 poin] Hitung jarak antar titik untuk semua pasangan karyawan menggunakan **Euclidean Distance!** (*hint*: untuk memudahkan perhitungan selanjutnya, anda dapat mengisi matriks/tabel di atas)
6. [14 poin] Anda diminta untuk menyelidiki dua nilai ϵ , yakni $\epsilon = 10$ dan $\epsilon = 20$. Untuk masing-masing ϵ , tentukan bagi setiap karyawan, **siapa** karyawan lain yang jaraknya **kurang dari ϵ** dan **berapa jumlahnya?**
7. [8 poin] Diketahui, Anda harus menggunakan parameter **MinPts = 4**. Berdasarkan penyelidikan Anda di nomor 6, nilai ϵ mana yang menurut Anda paling tepat? Jelaskan juga alasan Anda kenapa memilih nilai tersebut!
8. [8 poin] Berdasarkan hasil jawaban di nomor 6 dan 7, identifikasi siapa **core point**, **border point**, dan **noise/outlier!**

Insight [20 Poin]

Selanjutnya, rangkum apa saja *insight* yang Anda peroleh dengan menjawab pertanyaan di bawah. Jawaban Anda akan menjadi masukan mengenai tindakan yang akan dilakukan Pak Mindat selanjutnya.

9. [5 poin] Setelah menemukan karyawan yang diduga memiliki log tidak wajar, apa tindakan atau masukan yang akan Anda sampaikan kepada Pak Mindat?
10. [8 poin] Berdasarkan perhitungan di atas, Metode Tukey's Fence mungkin saja mendeteksi seorang karyawan sebagai outlier, tetapi DBSCAN tidak, atau sebaliknya. Mengapa hal ini dapat terjadi?
11. [7 poin] Pada kondisi seperti apa Anda menyarankan Pak Mindat untuk menggunakan metode Tukey's Fence dan DBSCAN?

Jawaban dapat berupa hasil *scan* tulisan tangan pada kertas A4, hasil tulisan tangan digital, atau hasil ketik pada dokumen digital (Word, GDocs, dll.). Kumpulkan jawaban Tugas 3 sebelum **Sabtu, 22 Februari 2025 jam 23.59**. Jawaban dikumpulkan dalam format pdf dengan penamaan [Kelas]_Tugas3_[NPM]_[Nama].pdf. Contoh penamaan file: A_Tugas3_2106750894_ErlanggaAhmad.pdf.